


# Klaidos atsklidos mokymo algoritmas

Pavyzdys

# Vienasluoksnis perceptronas



Pasvertų įėjimų suma *net*:

$$net = \omega_0 + \sum_{k=1}^p \omega_k x_k$$

Neurono išėjimas:

$$y = f\left(\omega_0 + \sum_{k=1}^p \omega_k x_k\right)$$


$$y = f(net)$$

Perdavimo funkcija:

sigmoidė  $f(net) = \frac{1}{1 + e^{-net}}$

tiesinė  $f(net) = net$

# Sigmoidinė perdavimo funkcija $f$



$$f(net) = \frac{1}{1 + e^{-net}}$$

# Vidutinė kvadratinė klaida *mse*

- Vidutinė kvadratinė klaida (*mean square error, mse*) tarp laukiamo ir stebimo išėjimo:

$$mse = \frac{1}{2} \frac{1}{N_1 + N_2} \sum_{i=1}^2 \sum_{j=1}^{N_i} (t_j^i - y_j^i)^2$$

$y_j^i$  – stebimas išėjimas

$t_j^i$  – laukiamas išėjimas

$j$  – įėjimo vektoriaus  $\mathbf{x}$  indeksas

$i$  – įėjimo vektoriaus  $\mathbf{x}$  klasė (2 klasės)


$k$  – įėjimo vektoriaus  $\mathbf{x}$  komponentė  $x_k$

$N_i$  – vektorių skaičius  $i$ -tojoje klasėje

# 1. Sklidimas pirmyn

$$\omega_k \rightarrow net \rightarrow y \rightarrow mse$$

Skaičiavimai:  $y$ ,  $mse$




## 2. Sklidimas atgal

$$\omega_k \leftarrow net \leftarrow y \leftarrow mse$$

dalinės  $mse$  išvestinės:

$$\frac{\partial mse}{\partial \omega_k} = \frac{\partial mse}{\partial y} \frac{\partial y}{\partial net} \frac{\partial net}{\partial \omega_k}$$

$$\frac{\partial mse}{\partial \omega_k} = \delta_{output\_layer} \frac{\partial net}{\partial \omega_k}$$



## 2. Dalinės *mse* išvestinės

$$\omega_k \leftarrow net \leftarrow y \leftarrow mse$$

$$\frac{\partial mse}{\partial \omega_k} = \frac{\partial mse}{\partial y} \frac{\partial y}{\partial net} \frac{\partial net}{\partial \omega_k}$$

$$\frac{\partial mse}{\partial y} = (y - t)$$

$$\frac{\partial y}{\partial net} = y - y^2 = (1 - y)y$$

Sigmoidinė perdavimo funkcija *f*  
*Klasifikavimas*

$$\frac{\partial net}{\partial \omega_k} = x_k$$

$$\frac{\partial y}{\partial net} = 1$$

Tiesinė perdavimo funkcija *f*  
*Prognozavimas*


### 3. Svorio keitimas

Gradientinio nusileidimo taisyklė:

$$\omega_k \leftarrow \omega_k - \eta \frac{\partial mse}{\partial \omega_k}$$

$$\delta_{output} = (y - t)(1 - y)y$$


$$\mathbf{w}_k \leftarrow w_k - \eta \delta_{output} x_k$$



# Užduotis

Raskite svorius po vienos perceptrono mokymo iteracijos:

- Perceptrono įėjimai:  $x_1=0.5$ ,  $x_2=-0.2$ ,  $x_3=0.15$
- Svoriai:  $w_1=0.2$ ,  $w_2=2$ ,  $w_3=0.1$ ,  $w_0=1$
- Targetas:  $t=1$
- Mokymo greitis:  $\eta=0.1$
- Perdavimo funkcija – sigmoidinė.



$$f(net) = \frac{1}{1 + e^{-net}}$$

# 1. Sklidimas pirmyn

Pakaida *mse*:

$$mse = 1/2 (t - y)^2$$

Neurono perdavimo funkcijos *f* argumentas *net*:

$$net = \omega_0 + \sum_{k=1}^3 \omega_k x_k = 1 + 0.2 * 0.5 + 2 * (-0.2) + 0.1 * 0.15 = 0.715$$

Neurono išėjimas *y*:

$$y = f(net) = \frac{1}{1 + e^{-net}} = \frac{1}{1 + e^{-0.715}} = 0.6715$$

Pakaida *mse*:

$$mse = 1/2 (t - y)^2 = 0.5 * (1 - 0.6715)^2 = 0.053$$

Svoriai:  $w_1=0.2, w_2=2, w_3=0.1, w_0=1$   
Perceptrono įėjimai:  $x_1=0.5, x_2=-0.2, x_3=0.15$

## 2. Sklidimas atgal

Dalinių išvestinių analitinės išraiškos:

$$\frac{\partial mse}{\partial \omega_k} = \frac{\partial mse}{\partial y} \frac{\partial y}{\partial net} \frac{\partial net}{\partial \omega_k}$$

$$\frac{\partial mse}{\partial y} = (y - t)$$

$$\frac{\partial y}{\partial net} = (1 - y)y$$

$$\frac{\partial net}{\partial \omega_1} = x_1$$

## 2. Sklidimas atgal

Dalinių išvestinių reikšmės:

$$\frac{\partial mse}{\partial y} = (y - t) = (0.6715 - 1) = -0.328$$

$$\frac{\partial y}{\partial net} = (1 - y)y = (1 - 0.675) 0.675 = 0.22$$

$$\frac{\partial net}{\partial \omega_1} = x_1 = 0.5$$

$$\frac{\partial mse}{\partial \omega_1} = \frac{\partial mse}{\partial y} \frac{\partial y}{\partial net} \frac{\partial net}{\partial \omega_1} = -0.328 \times 0.22 \times 0.5 = -0.036$$

# Neurono klaida

$$\delta_{output} = \frac{\partial mse}{\partial y} \frac{\partial y}{\partial net} = -0.328 * 0.22 = -0.072$$

Ši neurono paklaida bus naudojama svorio pokyčiui rasti.

# 3. Svorio keitimas

Gradientinio nusileidimo taisyklė:

$$\mathbf{w}_1 \leftarrow w_1 - \eta \delta_{output} x_1$$

$$\mathbf{w}_1 \leftarrow w_1 - \Delta w_1$$

Svorio pokytis:

$$\Delta w_1 = \eta \delta_{output} x_1$$

$$\Delta w_1 = 0.1 * (-0.072) * 0.5 = -0.004$$

$$\eta = 0.1$$

Svorio  $\omega_1$  nauja reikšmė:

$$\omega_1 = 0.2 - (-0.004) = 0.2004$$

# 3. Svorio keitimas: grafinė iliustracija

Gradientinio nusileidimo taisyklė:

$$\mathbf{w_1} \leftarrow w_1 - \eta \delta_{output} x_1$$

Svorio  $\omega_1$  pokytis:

$$\Delta w_1 = \eta \delta_{output} x_1$$

Svorio pokytis  $\eta \delta_{output} x_1 = 0.1 * (-0.072) * 0.5 = -0.004$

